

UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

Trabajo Final

Minería de textos en avisos inmobiliarios del Perú: clasificación del tipo de inmueble, predicción del segmento de precio y de atributos faltantes

Renee Enriquez Montalvan (U202221447)

Juan Felipe Granados Allende (U202212216)

David Miguel Ramos Parihuaman (U202417368)

Carrera de Ciencias de la Computación, Facultad de Ingeniería, Universidad Peruana de Ciencias Aplicadas

CC219 Aplicaciones de Data Science, sección CC92

Docentes: Richard Fernando Fernández Vásquez, Gustavo Adolfo López Abarca y Carlos Fernando Montoya Cubas

30 de noviembre de 2026

Índice

Descripción del caso de uso ... 3
Contexto y problemática ... 3
Antecedentes ... 3
Interesados y objetivos ... 3
Preguntas del caso de uso ... 4
Descripción del conjunto de datos ... 4
Origen de los datos ... 4
Consideraciones y limitaciones ... 5
Análisis exploratorio de los datos (EDA) ... 5
Carga e inspección de los datos ... 5
Preprocesamiento y normalización de textos ... 5
Visualización de los datos ... 7
Propuesta de modelización ... 9
Modelización ... 10
P1: clasificación del tipo de inmueble ... 10
P2: predicción del segmento de precio ... 10
P3: predicción de dormitorios, baños y área ... 11
Publicación de los resultados ... 11
Resultados de la P1 ... 11
Resultados de la P2 ... 12
Resultados de la P3 ... 13
Conclusiones ... 14
Repositorio del proyecto ... 14
Referencias ... 14

Índice de figuras

Figura 1. Avisos por tipo de inmueble y operación ... 7
Figura 2. Distribución geográfica de los avisos ... 7
Figura 3. Longitud de los textos de los avisos ... 8
Figura 4. Precios de los departamentos en venta en Lima Metropolitana ... 8
Figura 5. Amenidades mencionadas en los departamentos en venta según segmento de precio ... 8
Figura 6. Bigramas más frecuentes por tipo de inmueble ... 9
Figura 7. Composición de la categoría “Otro” según el primer tipo mencionado ... 9
Figura 8. Datos faltantes en los campos estructurados que el texto sí menciona ... 9
Figura 9. Matriz de confusión normalizada del SVM lineal con TF-IDF en la P1 ... 12
Figura 10. Términos con mayor peso por segmento en la regresión logística de la P2 ... 13

Índice de tablas

Tabla 1. Variables originales del conjunto de datos del Perú ... 4
Tabla 2. Pasos de normalización del texto ... 6
Tabla 3. Subconjuntos de datos por pregunta ... 6
Tabla 4. Resumen de la propuesta de modelización ... 10
Tabla 5. Resultados de la P1 en el conjunto de prueba ... 11
Tabla 6. Revisión de la reclasificación de los avisos “Otro” según la palabra clave del título ... 12
Tabla 7. Resultados de la P2 en el conjunto de prueba ... 13
Tabla 8. Resultados de la P3 en la muestra de 300 avisos ... 14

Minería de textos en avisos inmobiliarios del Perú: clasificación del tipo de inmueble, predicción del segmento de precio y de atributos faltantes

Descripción del caso de uso

Contexto y problemática

Hoy la búsqueda de vivienda en el Perú suele empezar en internet: según un estudio difundido por Gestión (2025), la publicidad digital, que incluye redes sociales y portales inmobiliarios, es el punto de partida más frecuente de los compradores (22.4%). En esos portales cada aviso combina campos estructurados, como tipo, precio, área o dormitorios, con un título y una descripción que el anunciante redacta libremente.

El problema es que la parte estructurada suele estar incompleta o mal registrada: en los datos de este trabajo, uno de cada cinco avisos figura en la categoría genérica "Otro" y dos de cada tres no indican el número de dormitorios, mientras que el título y la descripción casi siempre están presentes. Así, los filtros del portal dejan fuera avisos que sí le interesan a quien busca. La falta de información es un problema reconocido del sector, pues entre enero y junio de 2026 el Indecopi impuso 269 sanciones a inmobiliarias, varias por no brindar información suficiente al consumidor (El Comercio, 2026), y los precios tampoco son fáciles de interpretar: en abril de 2026 el metro cuadrado en Lima iba desde S/ 2,956 en el Callao hasta S/ 9,268 en San Isidro (Infobae, 2026).

Antecedentes

Diversos estudios muestran que el texto de los avisos aporta información que no está en los campos estructurados. Nowak y Smith (2017) redujeron en más de 25% el error de un modelo de precios hedónicos al incorporar el texto de avisos de Atlanta; Shen y Ross (2021) midieron con procesamiento de lenguaje natural el valor de la información "blanda" de las descripciones; y Baur et al. (2023) comprobaron que incluir la descripción reduce hasta en 17% el error en la valoración automática de alquileres. Por otro lado, Dagdelen et al. (2024) mostraron que un modelo de lenguaje grande (LLM) puede extraer datos de un texto y devolverlos en un formato estructurado como JSON.

Por ello, este trabajo aplica minería de textos y procesamiento de lenguaje natural (NLP) a avisos inmobiliarios reales del Perú siguiendo las fases de CRISP-DM (Chapman et al., 2000); esta entrega completa el modelado, la evaluación y la publicación de los resultados que se propusieron en el trabajo parcial.

Interesados y objetivos

La solución está pensada para el portal inmobiliario, que necesita ordenar su oferta y completar sus filtros; para las personas que buscan vivienda, que necesitan encontrar avisos y entender su precio; y para los anunciantes, que necesitan publicar avisos completos. El objetivo general es desarrollar modelos de NLP que, a partir del texto de los avisos inmobiliarios del Perú, permitan clasificar el tipo de inmueble, predecir el segmento de precio y predecir los atributos que faltan en los campos estructurados. Para ello, los objetivos específicos son limpiar, anonimizar y normalizar el texto de los avisos; clasificar el tipo de inmueble y reclasificar los avisos "Otro"; predecir y explicar el segmento de precio de los

departamentos en venta; y predecir el número de dormitorios, el número de baños y el área a partir del texto.

Preguntas del caso de uso

El caso de uso responde tres preguntas que implican clasificación o predicción:

P1 (clasificación). ¿Es posible identificar el tipo de inmueble (departamento, casa, lote, local comercial u oficina) solo con el título y la descripción del aviso, y usar ese modelo para reclasificar los avisos registrados como "Otro", que son el 20.4% de los avisos únicos?

P2 (predicción). ¿Se puede predecir el segmento de precio (económico, medio o alto) de un departamento en venta en Lima Metropolitana usando el texto del aviso, y qué términos explican esa predicción?

P3 (predicción). ¿Se pueden predecir el número de dormitorios, el número de baños y el área del inmueble a partir del texto, para completar los datos que faltan, y un LLM lo hace mejor que las reglas?

Descripción del conjunto de datos

Origen de los datos

Los datos provienen de Properati, un portal latinoamericano de búsqueda de inmuebles que publicó parte de sus avisos como datos abiertos a través de Properati Data, con la condición de citar la fuente. Se usa el conjunto *Property Listings for 5 South American Countries*, publicado en Kaggle por Jacobsen (2020), del que se toma solo el archivo del Perú (107.5 MB), con 124,449 avisos publicados entre el 1 de marzo de 2019 y el 24 de marzo de 2020 y 25 variables. Son avisos reales, públicos y en español, y forman un conjunto semiestructurado: la parte estructurada sirve como etiqueta o como variable de apoyo, y el título y la descripción son la materia prima de los modelos de NLP. La Tabla 1 resume sus variables.

Tabla 1

Variables originales del conjunto de datos del Perú

Variable	Tipo	Descripción	% faltante
id	Texto	Identificador del aviso	0
ad_type	Categórica	Tipo de publicación (solo "Propiedad")	0
start_date, end_date, created_on	Fecha	Alta, baja y primera publicación	0
lat, lon	Numérica	Coordenadas del inmueble	5.1
l1 a l6	Categórica	País, región, provincia, distrito y dos niveles más	0 a 20.6; l5 y l6: 100
rooms, bedrooms, bathrooms	Numérica	Ambientes, dormitorios y baños	74.3 / 66.7 / 29.7
surface_total, surface_covered	Numérica	Área total y área techada (m²)	35.4 / 59.4
price, currency	Numérica, categórica	Precio publicado y su moneda (USD o PEN)	1.9 / 2.4
price_period	Categórica	Periodo del precio (solo "Mensual")	52.3
title, description	Texto libre	Título y descripción del aviso	0 / 0 (5 vacías)

Variable	Tipo	Descripción	% faltante
property_type	Categórica	Tipo de inmueble (10 categorías)	0
operation_type	Categórica	Venta, alquiler o alquiler temporal	0

Nota. Elaboración propia con base en Jacobsen (2020).

Consideraciones y limitaciones

Los precios son de oferta y corresponden a 2019 y comienzos de 2020, por lo que hoy son otros; aun así, la forma de redactar los avisos y su relación con el tipo de inmueble y el precio siguen siendo válidas para el objetivo del trabajo. Como la información la escriben los propios anunciantes, hay avisos repetidos, errores, precios extremos y datos personales, que se tratan en el preprocesamiento. Además, la mayoría de los avisos es de Lima, lo que limita las conclusiones para otras regiones.

Análisis exploratorio de los datos (EDA)

Carga e inspección de los datos

El análisis se realizó en Python, en un cuaderno de Google Colab incluido en el repositorio, con pandas, scikit-learn (Pedregosa et al., 2011), sentence-transformers, transformers, matplotlib y seaborn. El archivo se descarga desde Kaggle sin credenciales y contiene 124,449 avisos y 25 variables.

En la inspección se revisaron el tipo de cada variable, sus valores únicos, los faltantes y las estadísticas descriptivas. Cuatro variables no aportan información, porque el tipo de publicación y el país tienen un único valor y los dos últimos niveles administrativos están vacíos. Además, 21,024 avisos (16.9%) repiten exactamente el título y la descripción de otro. Los campos estructurados tienen muchos faltantes, sobre todo dormitorios (66.7%) y área techada (59.4%), mientras que el título nunca falta y solo cinco descripciones están vacías. El precio se publica en dólares o en soles e incluye valores poco realistas, desde 0 hasta más de 133 millones.

Preprocesamiento y normalización de textos

Limpieza de registros

Se eliminaron los avisos duplicados por título y descripción, con lo que quedaron 103,425, y luego los que tenían la descripción vacía, con lo que quedaron 103,423. También se descartaron las cuatro variables sin información, los niveles de ubicación se renombraron como región, provincia y distrito, se creó un indicador de Lima Metropolitana y los tipos minoritarios (PH, cochera y casa de campo, 44 avisos) se agruparon en una sola categoría.

Normalización de textos

El título y la descripción se unieron en un solo texto, del que se generaron tres versiones: la primera solo recibe los pasos 1 y 2 de la Tabla 2 y la lee el LLM de la P3, que necesita los números tal como están escritos; la segunda agrega el paso 3 y conserva mayúsculas, tildes y signos para los sentence embeddings; y la tercera pasa por todos los pasos y se usa en TF-IDF.

Tabla 2

Pasos de normalización del texto

Paso	Qué se hace	Ejemplo
1. HTML	Se eliminan etiquetas y entidades HTML (28.5% de los avisos)	"Terraza. Cochera" → "Terraza. Cochera"
2. Anonimización	Se eliminan teléfonos (10.4%), correos y enlaces	"Cel. 9XX XXX XXX" → "Cel."
3. Montos	Los montos escritos (35.2%) se reemplazan por [MONTO] para que los modelos de la P2 no lean el precio	"PRECIO: S/. 85,000" → "PRECIO: [MONTO]"
4. Minúsculas y tildes	Se pasa a minúsculas y se quitan las tildes, salvo la ñ	"Baño Señorial" → "baño señorial"
5. Unidades	Se unifican las formas de escribir el área	"120 mts2", "120m²" → "120 m2"
6. Signos	Se quitan los signos de puntuación y los decimales ".0"	"4.0 baños" → "4 baños"
7. Stopwords	Se quitan las palabras vacías de NLTK, salvo "no" y "sin"	"sin muebles, no mascotas" → "sin muebles no mascotas"

Nota. Elaboración propia.

Con estos pasos, el vocabulario de una muestra de 5,000 avisos se redujo de 47,928 a 14,905 términos distintos.

Variables derivadas y subconjuntos

A partir del texto se calculó el número de palabras de cada aviso y se marcaron doce amenidades (piscina, cochera, terraza, vista al mar y ascensor, entre otras). También se extrajeron con expresiones regulares los dormitorios, los baños y el área que menciona el texto, que son la línea base de la P3. Las reglas reconocen números con separador de miles o escritos en palabras, el número antes o después del término, el medio baño y el área techada o de terreno; descartan distancias, precios por metro cuadrado, áreas parciales y baños de servicio, y dejan el dato vacío si el aviso da valores distintos. Por último, se definieron los subconjuntos de cada pregunta (Tabla 3).

Tabla 3

Subconjuntos de datos por pregunta

Pregunta	Subconjunto	Avisos
P1	Avisos de tipo departamento, casa, lote, local comercial u oficina (entrenamiento y prueba)	81,754
P1	Avisos "Otro" por reclasificar	21,077
P2	Departamentos en venta en Lima Metropolitana con precio en USD, sin el 1% de precios extremos de cada lado; segmentos por terciles: económico hasta 125,000 USD, medio hasta 235,000 USD y alto	22,509
P3	Departamentos y casas con dormitorios, baños y área total en los campos, de donde se toma la muestra de evaluación de 300 avisos	25,863

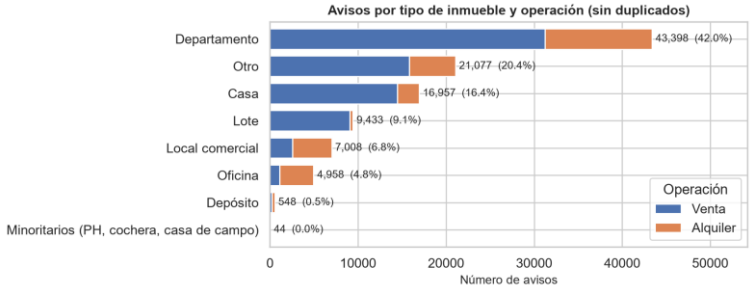
Nota. Elaboración propia.

Visualización de los datos

La Figura 1 muestra que el 42.0% de los avisos únicos son departamentos y que "Otro" es la segunda categoría, con 21,077 avisos (20.4%). El 72% de los avisos es de venta; solo en oficinas y locales comerciales predomina el alquiler.

Figura 1

Avisos por tipo de inmueble y operación

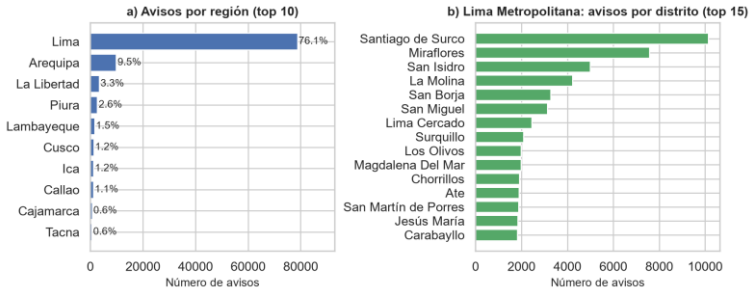


Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Los avisos se concentran en Lima (Figura 2): la región reúne el 76.1% y Lima Metropolitana el 71.9%, repartido en 43 distritos, con Santiago de Surco, Miraflores y San Isidro a la cabeza. Por eso la P2 se trabaja con Lima Metropolitana.

Figura 2

Distribución geográfica de los avisos



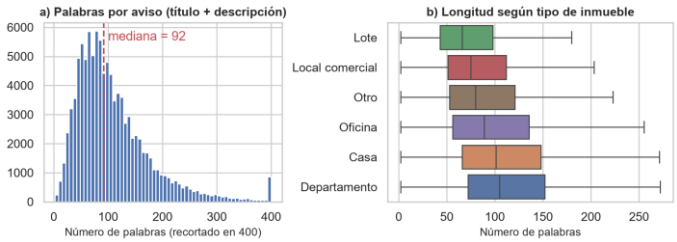
Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Los textos son cortos pero informativos (Figura 3): la mediana es de 92 palabras y la mitad de los avisos tiene entre 61 y 138; los departamentos y las casas tienen descripciones más largas que los lotes y locales.

El precio de los departamentos en venta de Lima Metropolitana tiene una distribución asimétrica, con mediana de 170,000 USD (Figura 4a), y sus terciles, 125,000 y 235,000 USD, definen los segmentos de la P2. El precio por metro cuadrado cambia mucho según el distrito (Figura 4b): Barranco, Miraflores y San Isidro superan los 2,000 USD/m², mientras que San Juan de Lurigancho, San Martín de Porres y Los Olivos no llegan a 1,000.

Figura 3

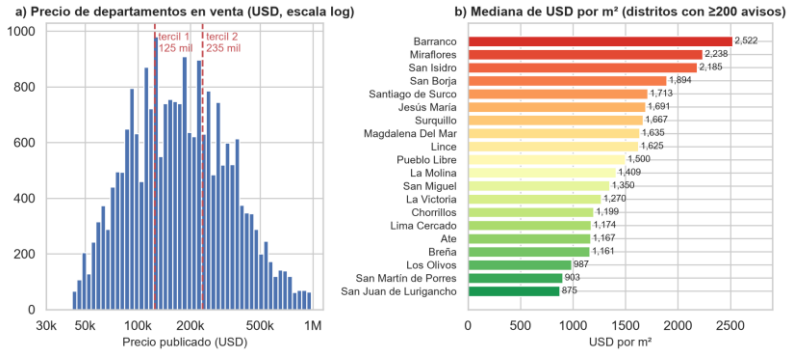
Longitud de los textos de los avisos



Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Figura 4

Precios de los departamentos en venta en Lima Metropolitana

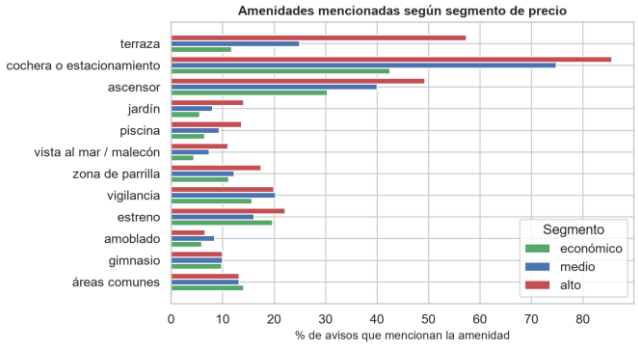


Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

El texto también describe características asociadas al precio (Figura 5): la terraza aparece en el 57.3% de los avisos del segmento alto frente al 11.8% del económico, y la cochera en el 85.6% frente al 42.5%, mientras que otras, como el gimnasio, casi no varían.

Figura 5

Amenidades mencionadas en los departamentos en venta según segmento de precio

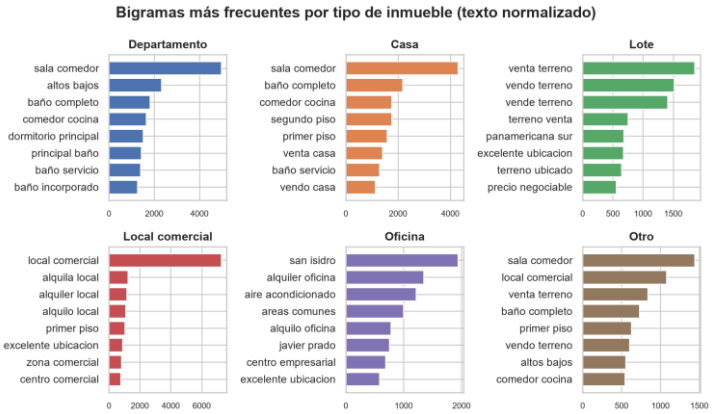


Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Los bigramas más frecuentes cambian según el tipo de inmueble (Figura 6): “sala comedor” y “dormitorio principal” en departamentos, “venta terreno” en lotes y “aire acondicionado” en oficinas. En “Otro” aparecen mezclados bigramas de todos los tipos, lo que sugiere que agrupa avisos mal categorizados.

Figura 6

Bigramas más frecuentes por tipo de inmueble



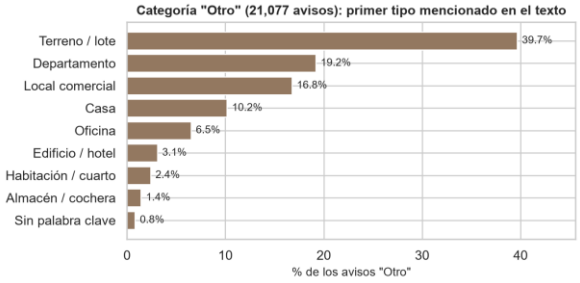
Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Para comprobarlo, se buscó la primera palabra que indica un tipo de inmueble en el título de cada aviso "Otro" (Figura 7): el 39.7% son terrenos, el 19.2% departamentos, el 16.8% locales, el 10.2% casas y el 6.5% oficinas, y solo el 7.7% corresponde a otros tipos o no menciona ninguno. La gran mayoría podría reubicarse en una de las cinco clases de la P1.

Por último, la Figura 8 compara los campos estructurados con lo que dice el texto en departamentos, casas y avisos "Otro". Al 61.0% le falta el número de dormitorios, pero en el 44.6% de esos avisos el texto lo indica, y en el área se puede completar el 64.9% de los faltantes. Cuando ambos datos existen, las reglas coinciden con el campo en el 83.4% de los dormitorios y el 84.8% de las áreas, pero solo en el 58.9% de los baños, lo que anticipa la dificultad de este campo en la P3.

Figura 7

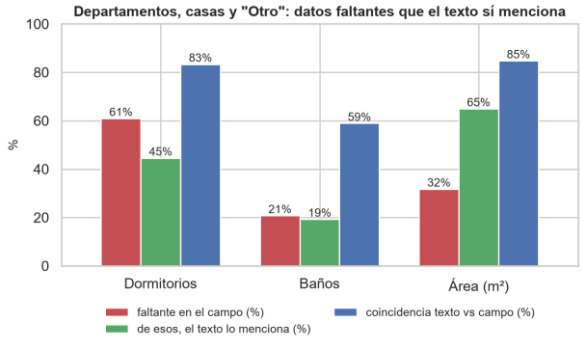
Composición de la categoría "Otro" según el primer tipo mencionado



Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Figura 8

Datos faltantes en los campos estructurados que el texto sí menciona



Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Propuesta de modelización

Para responder las preguntas se usan técnicas vistas en el curso: dos representaciones del texto, una léxica (TF-IDF; Salton y Buckley, 1988) y otra semántica (sentence embeddings; Reimers y Gurevych, 2019), con clasificadores lineales para la P1 y la P2, y un

LLM con salida en formato JSON para la P3. Respecto al trabajo parcial, la propuesta se ajustó a las tres preguntas de clasificación y predicción que pide el enunciado: la búsqueda semántica queda como trabajo futuro, por lo que la antigua P4 pasa a ser la P3, y se dejaron de lado el ajuste fino de BETO, la clasificación zero-shot y la interfaz gráfica. La Tabla 4 resume la propuesta.

Tabla 4

Resumen de la propuesta de modelización

Pregunta	Tarea	Modelos	Métricas
P1	Clasificación en 5 tipos y reclasificación de "Otro" con la opción "Ninguno"	TF-IDF con Naive Bayes, regresión logística y SVM lineal; sentence embeddings con regresión logística y SVM lineal	Accuracy, F1 macro, matriz de confusión; coincidencia con la palabra clave del título en "Otro"
P2	Clasificación en 3 segmentos de precio	Solo variables estructuradas (HistGradientBoosting y regresión logística); texto con TF-IDF o embeddings y regresión logística; texto más variables estructuradas	Accuracy, F1 macro y F1 por segmento; coeficientes del modelo
P3	Predicción de dormitorios, baños y área a partir del texto	Reglas con expresiones regulares; LLM Qwen3-1.7B con salida JSON validada; reglas más LLM	Cobertura, precisión en lo que responde y aciertos sobre el total

Nota. Elaboración propia.

Modelización

Todo se ejecutó en Google Colab con GPU. En la P1 y la P2 se usó una partición estratificada de 80% para entrenamiento y 20% para prueba con semilla fija, y las métricas se calculan sobre la prueba.

P1: clasificación del tipo de inmueble

Se entrenó con los 81,754 avisos de tipo conocido: 65,403 para entrenamiento y 16,351 para prueba. TF-IDF se calculó sobre el texto normalizado, con unigramas y bigramas que aparecen en al menos tres avisos y hasta 200,000 términos. Los sentence embeddings se calcularon sobre el texto con montos enmascarados con el modelo multilingüe paraphrase-multilingual-MiniLM-L12-v2 (Reimers y Gurevych, 2020), que genera vectores de 384 dimensiones y lee hasta 128 tokens. Con cada representación se entrenaron una regresión logística y un SVM lineal con pesos balanceados por clase, y con TF-IDF también un Naive Bayes complementario, que no admite los valores negativos de los embeddings.

Los avisos "Otro" no tienen etiqueta y algunos no son de ninguna de las cinco clases, como habitaciones o edificios. Por eso se agregó la opción "Ninguno": si el puntaje más alto del SVM queda por debajo del valor que conserva el 95% de las predicciones correctas en prueba (0.389), el aviso no se reclasifica. Para revisar el resultado se usó la primera palabra de tipo que aparece en el título.

P2: predicción del segmento de precio

Se usaron los 22,509 departamentos en venta: 18,007 para entrenamiento y 4,502 para prueba. Se compararon tres fuentes: solo variables estructuradas (distrito, área, dormitorios y

baños), solo el texto con los montos enmascarados (TF-IDF o embeddings) y ambas juntas. Para las variables estructuradas se usaron HistGradientBoosting, que maneja faltantes y categorías, y una regresión logística, para comparar con la misma familia de modelo que usan los modelos con texto. La explicación se hace con los coeficientes de la regresión logística con TF-IDF, que asigna un peso a cada término en cada segmento.

P3: predicción de dormitorios, baños y área

Para medir el desempeño se tomó una muestra aleatoria de 300 de los 25,863 departamentos y casas que sí tienen dormitorios, baños y área total en los campos, y lo que sale del texto se compara con el valor del campo. En el trabajo parcial se planteó etiquetar la muestra a mano, pero se optó por usar los campos de Properati porque permiten una evaluación automática y repetible; su limitación se discute en los resultados.

Se compararon tres métodos: las reglas del preprocesamiento; el LLM Qwen3-1.7B (Qwen Team, 2025), un modelo abierto de 1.7 mil millones de parámetros que, siguiendo el enfoque de Dagdelen et al. (2024), recibe el aviso con las mismas convenciones de las reglas y responde solo con un JSON que luego se valida; y la combinación de ambos, en la que el LLM solo completa lo que las reglas dejan vacío. Se miden la cobertura, la precisión en los avisos donde el método responde y los aciertos sobre el total; en el área se acepta una diferencia de hasta 5% con el área total o la techada.

Publicación de los resultados

Resultados de la P1

La Tabla 5 muestra que TF-IDF supera a los sentence embeddings con los dos algoritmos que se probaron en ambas representaciones. El mejor modelo es el SVM lineal con TF-IDF, con un F1 macro de 0.942; con embeddings, el mejor resultado es 0.878, unos seis puntos menos. Una posible explicación, que no se comprobó, es que cada tipo se distingue por palabras muy propias, que TF-IDF guarda como variables separadas, mientras que el embedding resume el aviso en un solo vector y solo lee los primeros 128 tokens.

Tabla 5

Resultados de la P1 en el conjunto de prueba

Representación	Modelo	Accuracy	F1 macro
TF-IDF	Naive Bayes (Complement)	0.938	0.907
TF-IDF	Regresión logística	0.961	0.941
TF-IDF	SVM lineal	0.962	0.942
Sentence embeddings	Regresión logística	0.905	0.866
Sentence embeddings	SVM lineal	0.916	0.878

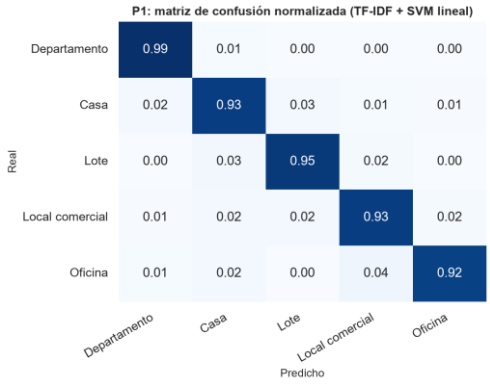
Nota. Elaboración propia.

En la matriz de confusión del mejor modelo (Figura 9), departamento es la clase que mejor se reconoce, con un recall de 0.987, y los errores más comunes ocurren entre casa y lote (3% en cada sentido) y en oficinas clasificadas como local comercial (4%). Son confusiones razonables, porque hay avisos que mezclan ambos tipos, como casas que se venden como terreno.

Al aplicar el modelo a los 21,077 avisos "Otro", 17,752 se reclasifican en una de las cinco clases y el 15.8% queda como "Ninguno"; del total, el 35.8% pasa a lote, el 19.7% a departamento y el 14.6% a local comercial. La Tabla 6 compara la predicción con la palabra clave del título: cuando esta nombra uno de los cinco tipos, el modelo coincide en el 86.6% de los avisos, mientras que la mayoría de los que nombran otro tipo de inmueble o ninguno se envían a "Ninguno". La opción funciona, aunque no es perfecta, porque el 35.5% de los avisos de otros tipos todavía termina en alguna clase.

Figura 9

Matriz de confusión normalizada del SVM lineal con TF-IDF en la P1



Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Tabla 6

Revisión de la reclasificación de los avisos "Otro" según la palabra clave del título

Palabra clave en el título	Avisos	Enviados a "Ninguno" (%)	Coinciden con la palabra clave (%)
Uno de los cinco tipos	19,451	11.5	86.6
Otro tipo (habitación, edificio, almacén)	1,455	64.5	No aplica
Sin palabra clave	171	89.5	No aplica

Nota. Elaboración propia.

Resultados de la P2

En la P2 (Tabla 7), el texto solo con TF-IDF alcanza un F1 macro de 0.828 y supera a los modelos que usan solo las variables estructuradas, que en este subconjunto tienen muchos vacíos (por ejemplo, el 52.2% no indica los dormitorios). El mejor resultado se obtiene al juntar TF-IDF con las variables estructuradas (0.866), lo que indica que el texto aporta información propia. Los embeddings rinden bastante menos: 0.626 solo con el texto y 0.792 junto con las variables estructuradas. Con la misma regresión logística, agregar TF-IDF a las variables estructuradas sube el F1 macro de 0.773 a 0.866, mientras que agregar embeddings solo lo sube a 0.792.

El segmento medio es el más difícil (F1 de 0.750 frente a 0.862 del económico y 0.873 del alto), lo que tiene sentido porque limita con los otros dos. En los coeficientes (Figura 10), el modelo se apoya en el distrito, con Miraflores y San Isidro hacia el segmento alto y Los Olivos, Chorrillos o Ate hacia el económico, y en características como "cocheras", "terraza" o "dúplex" en el alto y "kitchenette" o "no cochera" en el económico; los números

que aparecen son sobre todo áreas, pues van seguidos de “m2” entre el 58% y el 69% de las veces. Es posible que estos detalles se pierdan al resumir el aviso en un embedding, lo que explicaría su bajo rendimiento en esta pregunta.

Tabla 7

Resultados de la P2 en el conjunto de prueba

Fuente	Modelo	Accuracy	F1 macro
Solo estructuradas	HistGradientBoosting	0.796	0.796
Solo estructuradas	Regresión logística	0.774	0.773
Solo texto	TF-IDF + regresión logística	0.829	0.828
Solo texto	Embeddings + regresión logística	0.631	0.626
Texto + estructuradas	TF-IDF + regresión logística	0.867	0.866
Texto + estructuradas	Embeddings + regresión logística	0.793	0.792

Nota. Elaboración propia.

Figura 10

Términos con mayor peso por segmento en la regresión logística de la P2



Nota. Elaboración propia con datos de Properati (Jacobsen, 2020).

Resultados de la P3

El LLM devolvió un JSON válido en los 300 avisos. Según la Tabla 8, en dormitorios y baños da un valor en más del 90% de los avisos, frente al 67.0% y 46.3% de las reglas, y aunque acierta algo menos cuando responde, acierta más sobre el total. La combinación de reglas y LLM es la mejor en dormitorios (74.0%) y en área (45.0%), y en baños queda casi igual que el LLM solo; en el área el LLM responde menos que las reglas, así que ahí las reglas funcionan mejor. Además, el LLM tardó 112 s en procesar los 300 avisos, mientras que las reglas procesaron los 103,423 avisos en 24 s, por lo que conviene usarlo solo donde las reglas no encuentran el dato.

Los baños son el campo más difícil. En los 139 avisos donde las reglas encuentran el dato, las reglas aciertan el 61.9% y el LLM el 63.3%, así que sobre los mismos avisos el LLM no es peor. La precisión de ambos baja cuando el aviso menciona baños de servicio, de visita o medio baño (45.5% las reglas y 41.9% el LLM, frente a 72.6% y 63.7%), y 92 de los 128 desacuerdos del LLM con el campo son de un solo baño. Junto con la baja coincidencia entre texto y campo vista en el EDA (58.9%), esto sugiere que el campo de Properati no siempre cuenta esos baños igual y que parte del error podría estar en la referencia, aunque confirmarlo requiere revisar avisos a mano.

Tabla 8

Resultados de la P3 en la muestra de 300 avisos

Campo	Método	Cobertura (%)	Precisión en lo que responde (%)	Aciertos sobre el total (%)
Dormitorios	Reglas	67.0	85.1	57.0
Dormitorios	LLM (Qwen3-1.7B)	90.7	79.4	72.0
Dormitorios	Reglas + LLM	92.0	80.4	74.0
Baños	Reglas	46.3	61.9	28.7
Baños	LLM (Qwen3-1.7B)	91.7	53.5	49.0
Baños	Reglas + LLM	92.0	52.5	48.3
Área	Reglas	52.7	81.6	43.0
Área	LLM (Qwen3-1.7B)	46.7	79.3	37.0
Área	Reglas + LLM	55.0	81.8	45.0

Nota. Elaboración propia.

Conclusiones

En este trabajo se aplicaron técnicas de minería de textos y NLP a 103,423 avisos inmobiliarios del Perú, previamente limpiados y anonimizados. Para la P1, TF-IDF con un SVM lineal identifica el tipo de inmueble con un F1 macro de 0.942 y permitió reclasificar 17,752 avisos “Otro”, dejando como “Ninguno” a los que no se parecen a ninguna clase. Para la P2, el texto solo predice el segmento de precio con un F1 macro de 0.828 y junto con las variables estructuradas llega a 0.866; los coeficientes muestran que pesan sobre todo el distrito, la cochera, la terraza y el área. En ambas preguntas los sentence embeddings quedaron por debajo de TF-IDF, un resultado negativo para ese enfoque con estos datos. Para la P3, el LLM Qwen3-1.7B devolvió un JSON válido en todos los avisos y, combinado con las reglas, elevó los aciertos de dormitorios de 57.0% a 74.0%, aunque en baños el resultado sigue siendo bajo (49.0%) y parece que el campo de referencia no cuenta igual los baños de servicio o de visita. Como trabajo futuro quedan etiquetar a mano una muestra para evaluar mejor la P3, probar modelos que lean textos más largos o con ajuste fino, y construir el buscador semántico planteado en el trabajo parcial.

Repositorio del proyecto

El código, los datos y el archivo README están en el repositorio CC219-TP-TF-2026-2-CC92: https://github.com/DavidRamPari/CC219-TP-TF-2026-2-CC92. La carpeta data contiene el conjunto original, el conjunto final con 103,423 avisos y 41 variables, y la muestra de la P3 con las respuestas de las reglas y del LLM; la carpeta code contiene el cuaderno con todo el análisis.

Referencias

Baur, K., Rosenfelder, M., & Lutz, B. (2023). Automated real estate valuation with machine learning models using property descriptions. *Expert Systems with Applications, 213*, Artículo 119147. https://doi.org/10.1016/j.eswa.2022.119147

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.

Dagdelen, J., Dunn, A., Lee, S., Walker, N., Rosen, A. S., Ceder, G., Persson, K. A., & Jain, A. (2024). Structured information extraction from scientific text with large language models. *Nature Communications, 15*, Artículo 1418. https://doi.org/10.1038/s41467-024-45563-x

El Comercio. (2026, 8 de junio). *Indecopi impone más de 260 sanciones en el sector inmobiliario por infringir derechos de los consumidores*. https://elcomercio.pe/economia/peru/indecopi-impone-mas-de-260-sanciones-en-el-sector-inmobiliario-por-infringir-derechos-de-los-consumidores-l-ultimas-noticia/

Gestión. (2025, 16 de enero). *Búsqueda de viviendas: los tres canales más usados para encontrar el inmueble deseado*. https://gestion.pe/tu-dinero/inmobiliarias/busqueda-de-viviendas-los-tres-canales-mas-usados-para-encontrar-el-inmueble-deseado-noticia/

Infobae. (2026, 9 de mayo). *Este es el nuevo distrito más caro para comprar un departamento: superó a Barranco con un precio promedio de S/ 9.268*. https://www.infobae.com/peru/2026/05/09/este-es-el-nuevo-distrito-mas-caro-para-comprar-un-departamento-supero-a-barranco-con-un-precio-promedio-de-s-9268/

Jacobsen, R. (2020). *Property listings for 5 South American countries* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/rmjacobsen/property-listings-for-5-south-american-countries

Nowak, A., & Smith, P. (2017). Textual analysis in real estate. *Journal of Applied Econometrics, 32*(4), 896–918. https://doi.org/10.1002/jae.2550

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Qwen Team. (2025). *Qwen3-1.7B* [Modelo de lenguaje]. Hugging Face. https://huggingface.co/Qwen/Qwen3-1.7B

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En *Proceedings of EMNLP-IJCNLP 2019* (pp. 3982–3992). Association for Computational Linguistics. https://doi.org/10.18653/v1/D19-1410

Reimers, N., & Gurevych, I. (2020). Making monolingual sentence embeddings multilingual using knowledge distillation. En *Proceedings of EMNLP 2020* (pp. 4512–4525). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-main.365

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management, 24*(5), 513–523. https://doi.org/10.1016/0306-4573(88)90021-0

Shen, L., & Ross, S. (2021). Information value of property description: A machine learning approach. *Journal of Urban Economics, 121*, Artículo 103299. https://doi.org/10.1016/j.jue.2020.103299